Departamento de Estadística e Investigación Operativa

MASTER DATA&SCIENCE Y BIG DATA

MACHINE LEARNING I

(Trabajo de Rafael Pino y María Dolores Cubiles)

Se entregarán todos los ficheros de instrucciones (R o Python) y las presentaciones en un zip, mediante la herramienta de mensaje de curso a Rafael Pino (se pueden generar archivos .RMarkdown o bien Jupyter Notebook). Plazo de entrega: 6 de Abril.

Descargar los archivos **datos.RData** y **GenerarDatos.R**. Generar el conjunto de datos mediante las instrucciones

```
m=          #cinco primeras cifras del DNI
source("GenerarDatos.R")
```

Se obtendrá así un *data frame* de nombre **datos**, con 1000 casos, que contiene la variable *label* (categórica distinguiendo dos tipos de prendas) y 10 variables potencialmente predictoras de label (son el contenido de 10 píxeles entre los 784 píxeles en nivel de gris de cada imagen de resolución 28x28). También se habrá generado un subconjunto de datos, de nombre **datosred**, formado por 75 casos.

1) Trabajando con **datosred**, sin utilizar la variable *label*, aplicar e interpretar dos técnicas de análisis de conglomerados,
2) Siguiendo también con **datosred,** configurar un modelo knn ponderado mediante validación cruzada, y estimar la capacidad de generalización de dicho modelo mediante el método bootstrap 632+.
3) A continuación, realizar una partición en subconjuntos de entrenamiento y test (75% y 25%) de los 1000 casos de **datos**, que serán utilizados de forma conveniente. Construir un modelo Naive-Bayes en el que se estimarán las funciones de densidad mediante el método núcleo. Estimar la capacidad de generalización mediante los porcentajes de acierto global y para cada categoría, así como la curva operativa característica y AUC.