Evaluación Machine Learning I y II

Dataset DUNGEONS — Predicción de dificultad en mazmorras RPG

Master Propio en Data Science. Universidad de Sevilla

Normas de uso de Chatbots y LLM

El objetivo de esta evaluación es verificar la comprensión de los algoritmos estudiados y la capacidad de aplicación práctica. Para garantizar la equidad y la transparencia, se establecen las siguientes directrices:

1. Recursos y Herramientas

- **Acceso ilimitado:** Los estudiantes podrán utilizar cualquier recurso disponible, incluyendo conexión a Internet y herramientas de inteligencia artificial (chatbots/LLMs).
- **Colaboración:** No se permite la discusión entre compañeros ni la realización de trabajos conjuntamente. La sospecha de copia conllevará sanción.

2. Protocolo de Uso de Inteligencia Artificial (Chatbots)

El uso de LLMs (como ChatGPT, Gemini, Claude, etc.) está permitido como herramienta de apoyo, pero no queremos comprobar cómo ChatGPT o Gemini responden a las preguntas, porque ya sabemos cómo lo hacen y los resultados han sido interesantes. Por tanto, su uso debe ser declarado y gestionado bajo las siguientes condiciones:

- **Declaración Previa:** El estudiante debe informar al profesor en su trabajo si va a utilizar un chatbot para cualquier parte de R.
- **Transparencia:** Si se opta por usar un chatbot, el estudiante deberá:
    1. Notificar al profesor en su trabajo cada vez que la información o el código provengan de una IA.
    2. Incluir en la entrega una descripción de los *prompts* utilizados para generar dichas respuestas.
    3. Identificar y corregir cualquier error presente en la respuesta de la IA, explicando la naturaleza del error.
- **Responsabilidad:** El estudiante es el único responsable de la validez de las respuestas entregadas. Los errores derivados de un uso incorrecto o no verificado de la IA tendrán un peso negativo superior al de un error humano honesto.

3. Restricciones y Sanciones

- **Sin IA:** Si el estudiante declara no usar chatbots, cualquier detección de contenido generado por IA se considerará plagio y se sancionará conforme a la normativa de la Universidad de Sevilla.
- **Incumplimiento:** No seguir el protocolo de declaración y descripción de los *prompts* se considerará una falta académica grave, con las sanciones correspondientes.

Introducción al Dataset

El dataset **DUNGEONS** simula los niveles de un videojuego RPG de fantasía tipo *dungeon-crawler*. Cada observación representa una **mazmorra** (sala de combate), cuyos 5 enemigos se describen mediante su posición en la sala y su poder de combate. El objetivo es predecir el **RANGO** de dificultad del nivel.

Variable	**Descripción**
`ID`	Identificador único de la mazmorra
`N_ENEMIES`	Número de enemigos (constante = 5)
`RANGO`	Dificultad ordinal: Bronce < Plata < Oro < Platino < Diamante < Maestro
`i_X`, `i_Y`, `i_Z` ($i = 1..5$)	Posición 3D del enemigo i en la sala (metros)
`i_PODER` ($i = 1..5$)	Nivel de combate del enemigo i

Apartado 1 Preparación del Dataset

Carga y prepara adecuadamente el dataset `dungeons.csv`. Usa un conjunto de **entrenamiento del 75 %** y de **test del 25 %**. Usa la semilla **(1234)** en cada operación aleatoria.

Apartado 2 CART, Random Forest y Red Neuronal

Utiliza **CART**, **Random Forest** y una **red neuronal con entre 5 y 8 neuronas** en la capa oculta para predecir el RANGO de dificultad. Intenta obtener la mejor versión de cada algoritmo, teniendo en cuenta que:

- Debes podar el árbol que debes dejar crecer hasta un cp de 0.05.
- Indica el número de variables que intervienen en los cortes del Random Forest.
- Mantén un decay de 0.01 en la red neuronal pero indica claramente el número de neuronas de capa oculta usado.

Compara los modelos e indica cuál produce mejores resultados.

Apartado 3 Análisis de Componentes Principales (ACP)

Realiza un **ACP** sobre las variables explicativas. Interpreta el resultado y razona cuántas componentes principales serían apropiadas para no perder demasiada información.

Apartado 4 Algoritmo Genético para Selección de Variables

Usa un **algoritmo genético** para seleccionar el mejor subconjunto de variables explicativas con la red neuronal del Apartado 2. Usa popSize = 30, maxiter = 40, pmutation = 0.10, pcrossover = 0.80. Justifica la elección de la funcción fitness usada. Indica las variables seleccionadas y el valor fitness de la mejor solución.

Apartado 5 Variable Dicotómica DIFICIL

Se considera que una mazmorra es **difícil** si su RANGO es *estrictamente mayor* que `"Platino"`. Crea la variable `DIFICIL`.

Apartado 6 SVM para Clasificación Dicotómica

Usa el mejor **SVM** radial posible para clasificar mazmorras en difícil / no difícil usando las variables espaciales y de poder. Para ello, restringe los posibles valores de los parámetros del SVM radial a cost = 0.1, 1, 10, 100; y gamma = 0.001, 0.01, 0.1, 1.

Apartado 7 El Problema Añadido

Describe el problema añadido detectado y propón soluciones.

Apartado 8 Clasificación Balanceada con SVM y Perceptrón Simple

Usa una de las soluciones propuestas para rehacer la clasificación con **SVM** y con un **perceptrón simple**. Compara los resultados. ¿Qué predice cada modelo para la mazmorra con `ID = 40`?